

Guía del Proyecto Final

Del Dato al Modelo: Análisis del Tamaño de Mercado de Vehículos Eléctricos

Master en Data Science + AI | Proyecto integrador de Python, Estadística, Análisis de Datos y **Machine Learning**

Propósito de la guía: orientar paso a paso la construcción de un proyecto final completo, desde la obtención del dataset hasta la generación de conclusiones y recomendaciones estratégicas basadas en datos.

1. Contexto general del proyecto

El Proyecto Final integra las competencias desarrolladas durante el Master en Data Science + AI y las aplica a un problema de negocio real: analizar el tamaño, comportamiento y posible crecimiento del mercado de vehículos eléctricos, conocidos como EV por sus siglas en inglés.

La intención no es únicamente entrenar un modelo. El objetivo es construir una solución analítica completa: entender el problema, trabajar con datos reales, limpiarlos, explorarlos, visualizarlos, modelarlos e interpretar los resultados para tomar decisiones.

1.1 Pregunta central del proyecto

La pregunta puede formularse de manera general así:

¿Cómo se comporta el mercado de vehículos eléctricos y qué patrones o predicciones pueden obtenerse a partir de datos reales?

A partir de esa pregunta principal, cada equipo o estudiante puede definir un enfoque específico: mercado global, análisis regional, comparación por país, comportamiento por año, segmentación por tipo de vehículo, proyección de crecimiento o agrupamiento de mercados similares.

1.2 Dataset del proyecto: vehículos eléctricos

El dataset debe provenir de registros reales de vehículos eléctricos, ventas, matriculaciones, parque vehicular, stock, tipo de tecnología o infraestructura asociada. La fuente debe ser verificable y documentada dentro del proyecto.

Fuente sugerida	Qué contiene	Uso recomendado
Washington State / Data.gov - Electric Vehicle Population Data	Registro de BEV y PHEV actualmente registrados en Washington State. Útil para análisis por marca, modelo, año, condado, ciudad y tipo de EV.	EDA, limpieza, análisis por segmento, clustering geográfico o por características.
IEA Global EV Data Explorer	Datos históricos y proyectados sobre ventas, stock, infraestructura de carga y desplazamiento de petróleo en vehículos eléctricos.	Tendencias temporales, proyecciones, análisis global/regional y regresión.
Kaggle - Electric Vehicle Population Dataset	Versiones replicadas o preparadas de datasets de vehículos eléctricos, normalmente en CSV y de uso sencillo para estudiantes.	Práctica rápida de notebooks, EDA, visualización y modelos básicos.

Fuentes de referencia consultadas: el portal Data.gov describe el conjunto Electric Vehicle Population Data como registros de BEV y PHEV registrados por el Department of Licensing de Washington State; la IEA mantiene el Global EV Data Explorer con datos históricos y proyectados de ventas, stock, infraestructura de carga y otros indicadores de vehículos eléctricos.

Consejo: no descarguen cualquier archivo sin revisar su origen. Un proyecto serio debe indicar de dónde provienen los datos, qué significan las columnas, cuándo fueron actualizados y cuáles son sus limitaciones.

2. Definir el alcance antes de programar.

Un proyecto sin alcance claro suele terminar con muchas gráficas desconectadas y conclusiones débiles.

Alcance posible	Pregunta guía	Variables probables
Global	¿Cómo evoluciona el mercado mundial de EV?	Ventas por año, stock global, participación por región.
Regional	¿Qué región crece más rápido?	Ventas por continente o zona económica.
País / Estado	¿Dónde se concentra la adopción de EV?	Registros por estado, condado, ciudad o código postal.
Segmento	¿Qué tipo de EV domina el mercado?	BEV, PHEV, modelos, marcas, años, autonomía.
Predicción	¿Cómo podría crecer el mercado?	Año, ventas, registros, tasas de crecimiento.
Clustering	¿Qué grupos de mercados o vehículos son similares?	Variables normalizadas y K-Means.

2.1 Entregable inicial del alcance

- Título tentativo del proyecto.
- Pregunta principal de análisis.
- Fuente del dataset y enlace o referencia.
- Variables principales que se analizarán.
- Modelo de Machine Learning tentativo: supervisado o no supervisado.
- Resultado esperado: insight, predicción, segmentación o recomendación.

3. Integración de módulos del Master

Módulo	Competencias	Cómo se evidencia en el proyecto
Módulo 1: Python	Variables, estructuras de datos, funciones, control de flujo, uso de librerías.	Scripts limpios, funciones para cargar/limpiar datos, notebooks reproducibles.
Módulo 2: Estadística	Media, mediana, dispersión, correlación, regresión lineal, interpretación estadística.	Resumen estadístico, análisis de relaciones, tasas de crecimiento.
Módulo 3: Análisis de Datos	Limpieza, EDA, outliers, visualización y narrativa visual.	DataFrame limpio, gráficos interpretados, patrones temporales y geográficos.
Módulo 4: Machine Learning	Modelado supervisado, no supervisado, normalización, evaluación de modelos.	Predicción, clustering, métricas, validación e interpretación.

4. Estructura obligatoria del proyecto final

El proyecto puede implementarse con libertad, pero debe cubrir los siguientes bloques. Cada bloque debe incluir código, explicación e interpretación.

4.1 Recopilación de datos

- Cargar el archivo CSV, Excel o fuente seleccionada.
- Identificar el origen del dataset y describirlo brevemente.
- Mostrar dimensiones: número de filas y columnas.
- Revisar nombres de columnas, tipos de datos y primeras filas.
- Documentar cualquier limitación evidente del dataset.

4.2 Limpieza de datos

- Revisar valores nulos y decidir si se eliminan, imputan o conservan.
- Eliminar duplicados si existen.
- Estandarizar nombres de columnas.
- Convertir fechas, años o variables numéricas al tipo correcto.
- Revisar categorías inconsistentes, errores de escritura o unidades mezcladas.
- Detectar outliers y justificar cómo se tratarán.

4.3 Exploración de datos

- Calcular estadísticas descriptivas.
- Analizar distribución de variables principales.
- Identificar tendencias por año, marca, región, tipo de EV o segmento.
- Calcular tasas de crecimiento si hay datos temporales.
- Explorar correlaciones cuando haya variables numéricas relevantes.

4.4 Visualización de datos

- Crear gráficos claros, etiquetados y con títulos informativos.
- Usar gráficas de línea para tendencias temporales.
- Usar barras para comparar marcas, regiones o segmentos.
- Usar dispersión para relaciones entre variables.
- Incluir interpretación debajo de cada gráfica.

4.5 Aprendizaje Automático

- Aplicar al menos un modelo supervisado o no supervisado.
- Justificar por qué ese modelo responde a la pregunta del proyecto.
- Si se usa supervisado, separar train/test y evaluar métricas.
- Si se usa KNN, normalizar los datos y justificar el valor de K.

- Si se usa K-Means, justificar el número de clusters con método del codo o Silhouette.
- Si se usa red neuronal, explicar entradas, salida, pérdida, épocas y evaluación.

4.6 Conclusiones y recomendaciones

- Resumir los hallazgos principales.
- Conectar los resultados con decisiones de negocio.
- Indicar limitaciones del análisis.
- Proponer mejoras o pasos futuros.
- Evitar conclusiones no respaldadas por datos.

5. Opciones de Machine Learning para el proyecto

Modelo	Cuándo usarlo	Evaluación	Consejo
Regresión lineal / regresión múltiple	Predecir una variable numérica, como ventas o registros futuros.	MAE, MSE, RMSE, R^2 .	Útil si existe tendencia aproximadamente lineal.
KNN	Clasificar observaciones por similitud, por ejemplo tipos de mercado o categorías definidas.	Accuracy, matriz de confusión, precision, recall, F1.	Normalización obligatoria. Elegir K con análisis de error.
K-Means	Agrupar países, regiones, marcas o vehículos sin etiquetas previas.	Método del codo, Silhouette score, interpretación de centroides.	El algoritmo agrupa; el analista interpreta.
Red neuronal simple	Predecir una variable continua con TensorFlow cuando se quiere mostrar aprendizaje mediante pesos.	Curva de pérdida, error de predicción, comparación visual.	No usar redes neuronales solo por complejidad; deben justificarse.

6. Pipeline recomendado de trabajo

1. Definir pregunta de negocio y alcance.
2. Descargar dataset desde fuente confiable.
3. Cargar datos en Python con pandas.
4. Explorar estructura: head(), info(), describe(), shape.
5. Limpiar datos: nulos, duplicados, tipos de datos, categorías.
6. Crear variables derivadas si aportan valor: año, edad del vehículo, tasa de crecimiento, segmento.
7. Realizar EDA con tablas y visualizaciones.
8. Seleccionar un enfoque de Machine Learning.
9. Preparar variables para el modelo.
10. Entrenar y evaluar el modelo.
11. Interpretar resultados con lenguaje de negocio.
12. Elaborar conclusiones, recomendaciones y limitaciones.

Regla profesional: no se debe entrenar un modelo antes de entender los datos. Primero se explora, se limpia y se justifica el enfoque. El modelo viene después.

7. Entregables del proyecto

Entregable	Contenido esperado	Criterio de calidad
Notebook o script Python	Código ejecutable, ordenado y comentado.	Debe correr de inicio a fin sin errores.
Documento o reporte	Explicación del problema, datos, análisis, modelos y conclusiones.	Debe leerse como una historia de datos, no como una lista de capturas.
Visualizaciones	Gráficos con títulos, ejes, leyendas e interpretación.	Cada gráfica debe responder una pregunta.
Modelo de ML	Modelo supervisado o no supervisado con evaluación.	Debe justificarse y evaluarse correctamente.
Presentación final	Síntesis ejecutiva del proyecto.	Debe comunicar hallazgos y recomendaciones.

8. Rúbrica sugerida de evaluación

Criterio	Peso	Descripción
Definición del problema y alcance	15%	Pregunta clara, fuente del dataset y objetivo bien delimitado.
Limpieza y preparación	20%	Manejo correcto de nulos, duplicados, tipos de datos y consistencia.
EDA y estadística	20%	Análisis descriptivo, correlaciones, tendencias y hallazgos justificados.
Visualización y narrativa	15%	Gráficos claros, interpretados y conectados con el problema.
Machine Learning	20%	Modelo justificado, entrenado, evaluado e interpretado.
Conclusiones y recomendaciones	10%	Conclusiones respaldadas por datos y recomendaciones estratégicas.

9. Errores comunes que deben evitarse

- Usar un dataset sin explicar su fuente.
- Copiar código sin entender qué hace cada paso.
- Hacer gráficas sin interpretar sus resultados.
- Entrenar un modelo sin limpiar los datos.
- Escalar todo el dataset antes de separar train/test, provocando fuga de información.
- Usar K-Means sin justificar el número de clusters.
- Reportar solo accuracy sin revisar matriz de confusión.
- Presentar conclusiones que no salen de los datos.
- Confundir correlación con causalidad.
- Usar una red neuronal cuando un modelo simple respondía mejor al problema.

10. Referencias sugeridas para la fuente de datos

- Washington State / Data.gov. Electric Vehicle Population Data. Dataset de vehículos eléctricos BEV y PHEV registrados en Washington State Department of Licensing.
- Washington State Open Data Portal. Electric Vehicle Population Data.
- International Energy Agency. Global EV Data Explorer. Herramienta de datos históricos y proyectados sobre ventas, stock, infraestructura de carga y otros indicadores de EV.
- International Energy Agency. Global EV Outlook 2025. Reporte de análisis sobre tendencias globales de vehículos eléctricos.